


# Support Vector Machine

Anna Przybyła

29.04.2020

# Support Vector Machine

- Cel: Na podstawie danych treningowych znaleźć algorytm, który przyporządkuje każdemu elementowi ze zbioru treningowego kategorię, do której należy.



- Dana jest próbka treningowa

$$D = \{(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_n, y_n)\}, \text{ gdzie } y_i \in \{-1, 1\}, \mathbf{x}_i \in \mathbb{R}^p$$

- Klasyfikatorem liniowym nazywamy funkcję

$$f_{\mathbf{w},b}(\mathbf{x}) = \text{sgn}(\mathbf{w} \cdot \mathbf{x} + b)$$

- Próbka  $D$  jest liniowo separowana jeśli istnieje klasyfikator liniowy  $f_{\mathbf{w},b}(\cdot)$  taki, że  $\forall i$

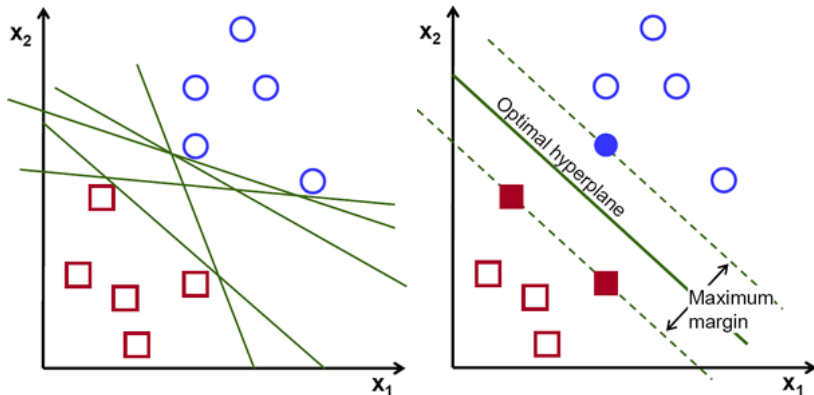
$$\mathbf{w} \cdot \mathbf{x}_i + b \geq +1, \text{ gdy } y_i = +1$$

$$\mathbf{w} \cdot \mathbf{x}_i + b < -1, \text{ gdy } y_i = -1$$

- Równoważnie

$$\forall i \quad y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1$$

# SVM - najlepszy klasyfikator liniowy




# SVM - najlepszy klasyfikator liniowy

- Niech  $M$  - minimum odległości punktów od hiperpłaszczyzny rozdzielającej  $\mathbf{w} \cdot \mathbf{x} + b = 0$
- Problem optymalizacyjny:


$$\max_{\mathbf{w}, b, \|\mathbf{w}\|=1} M \text{ przy } y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq M, \quad i = 1, \dots, N$$

- Równoważnie, przy założeniu  $\|\mathbf{w}\| = 1/M$

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \text{ przy } y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1, \quad i = 1, \dots, N$$



# SVM - przypadek nieseparowalny liniowo - nieznaczná nieseparowalność



# SVM - przypadek nieseparowalny liniowo - nieznaczną nieseparowalność


- Celem jest maksymalizacja  $M$ , ale przy dopuszczeniu niektórych punktów po złej stronie granicy
- Problem optymalizacyjny:

$$\min_{w,b} \frac{1}{2} ||w||^2 + C \sum_{i=1}^N \xi_i$$

$$\text{przy } y_i(\mathbf{w} \cdot \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0, \quad i = 1, \dots, N$$


- $C$  - parametr kosztu - określa, czy ważniejsze przy optymalizacji jest zmniejszenie liczby źle sklasyfikowanych punktów, czy zwiększenie szerokości granicy

# SVM - przypadek nieseparowalny liniowo - zmiana przestrzeni atrybutów





# SVM - przypadek nieseparowalny liniowo - zmiana przestrzeni atrybutów



- Rozwiązaniem problemu optymalizacyjnego jest


$$f(x) = \sum_{i=1}^N \alpha_i y_i \langle h(x), h(x_i) \rangle + b$$

- Funkcja jądrowa (kernel function)  $K(x, x') = \langle h(x), h(x') \rangle$
- często stosowane funkcje jądrowe:
  - liniowa:  $K(x, x') = \langle x, x' \rangle$
  - wielomianowa:  $K(x, x') = (1 + \langle x, x' \rangle)^d$
  - gaussowska:  $K(x, x') = \exp(-\gamma \|x - x'\|^2)$

# Przykład - R


Zbiór *Cats* zawierający dane o płci kotów, masie ciała i masie mięśnia sercowego.

Funkcja jądrowa liniowa,  $C=50$




## Funkcja jądrowa gaussowska


C=1



C=50



C=10e6



- Zalety

- SVM jest dobrą metodą przy braku wiedzy o danych.
- Kernel trick umożliwia efektywne rozwiązywanie problemów nieliniowych.
- Metoda działa efektywnie dla dużych wymiarów.

- Wady

- Metoda SVM jest mocno zależna od parametrów, których wartość trudno określić.
- Wybranie dobrej funkcji jądrowej jest trudne.
- Dla dużych zbiorów danych czas uczenia jest długi.
- Wyniki są trudne do interpretacji.

- Laura Auria, Rouslan A. Moro, *Support Vector Machines (SVM) as a Technique for Solvency Analysis*
- Tony Van Gestel, David Martens, Bart Baesens, Daniel Feremans, Johan Huysmans, Jan Vanthienen, *Forecasting and Analyzing Insurance Companies' Ratings*. International Journal of Forecasting 23 (2007) 513–529
- Vipula Rawte, G Anuradha, *Fraud Detection in Health Insurance using Data Mining Techniques*. 2015 International Conference on Communication, Information Computing Technology (ICCICT), Jan. 16-17, Mumbai, India
- Kentaro Kuwata, Faizan Mahmood and Ryosuke Shibasaki, *Weather index for crop insurance to mitigate basis risk*.